

Previsão de Ocorrência de Chuva em São Carlos a partir de Dados Meteorológicos Históricos: uma Análise Comparativa de Modelos de Classificação

Ana Paula de Abreu Batista (12688424)

Instituto de Ciências Matemáticas e de Computação (ICMC)

Universidade de São Paulo (USP) – São Carlos, SP, Brasil

anapbatista@usp.br

Resumo

A previsão da ocorrência de chuva é um problema clássico de séries climáticas com forte impacto em setores como agricultura, defesa civil, gestão de recursos hídricos e planejamento urbano. Este trabalho aborda o problema de previsão de chuva no município de São Carlos – SP como uma tarefa de classificação binária, utilizando uma base de dados meteorológicos diários (2006–2025), construída a partir de registros horários do Instituto Nacional de Meteorologia (INMET). Foram investigados e comparados quatro modelos de classificação supervisionada: *Random Forest*, *XGBoost*, *Multilayer Perceptron* (MLP) e Regressão Logística Polinomial (grau 2), todos implementados com a biblioteca `scikit-learn` (e `xgboost`). Os modelos foram avaliados por meio de validação cruzada de 5 *folds* e das métricas *Accuracy*, *Precision*, *Recall*, *F1-score* e área sob a curva ROC (AUC). Os resultados mostram desempenho equivalente entre os modelos em termos de acurácia (em torno de 0,84), mas com diferenças relevantes de *recall* para a classe "chuva", em que o modelo de Regressão Logística Polinomial obteve o melhor resultado (*recall* = 0,86; AUC = 0,924), seguido de perto pelo XGBoost. A umidade relativa do ar e a temperatura do ponto de orvalho foram identificadas como as variáveis mais relevantes para a predição.

Palavras-chave: previsão de chuva; aprendizado de máquina; classificação binária; Random Forest; XGBoost; Redes Neurais.

1 Introdução

A precipitação pluviométrica é uma das variáveis meteorológicas mais determinantes para a vida humana e para a economia de uma região. A ocorrência – ou a ausência – de chuva afeta diretamente a produtividade agrícola, o abastecimento de água, a geração de energia hidrelétrica, o planejamento de obras civis e a segurança da população frente a eventos extremos, como enchentes e deslizamentos de terra. Estima-se que entre 70% e 90% das perdas econômicas relacionadas a desastres naturais no mundo estejam associadas a eventos hidrometeorológicos, o que reforça a importância de sistemas confiáveis de previsão de curto prazo. No Brasil, municípios do interior paulista, como São Carlos – SP, apresentam um regime pluviométrico tropical de altitude, marcado por uma estação chuvosa bem definida

(primavera-verão) e uma estação seca (outono-inverno), o que torna o problema de prever a ocorrência diária de chuva particularmente relevante tanto para a gestão pública quanto para atividades agrícolas e urbanas locais.

A previsão de chuva é tradicionalmente realizada por meio de modelos numéricos de previsão do tempo (NWP), que demandam alto poder computacional e conhecimento físico detalhado da atmosfera. Como alternativa a essas abordagens, técnicas de Aprendizado de Máquina (AM) vêm sendo amplamente utilizadas para modelar a relação estatística entre variáveis meteorológicas de superfície (temperatura, umidade, pressão, radiação, vento, etc.) e a ocorrência de precipitação, sem a necessidade de resolver explicitamente as equações físicas da atmosfera.

Neste trabalho, o problema é formulado como uma tarefa de **classificação binária supervisionada**: dado um conjunto de variáveis climáticas observadas em um dia, o objetivo é prever se houve ou não precipitação ($\text{CHOVEU} = 1$ para precipitação total diária maior que 0 mm; $\text{CHOVEU} = 0$ caso contrário). Para resolver esse problema, foram implementados e comparados **quatro modelos de classificação**: (i) *Random Forest*, um *ensemble* de árvores de decisão; (ii) *XGBoost*, um algoritmo de *Gradient Boosting* otimizado; (iii) um *Multilayer Perceptron* (MLP), uma rede neural artificial *feedforward*; e (iv) uma Regressão Logística Polinomial de grau 2, que incorpora termos de interação entre as variáveis de entrada. Os quatro modelos foram treinados sobre o mesmo conjunto de atributos climáticos (8 *features* numéricas), com tratamento de desbalanceamento de classes via ponderação de classes (*class_weight* ou *scale_pos_weight*), e foram comparados segundo os critérios de *Accuracy*, *Precision*, *Recall*, *F1-score*, área sob a curva ROC (AUC) e estabilidade via validação cruzada de 5 *folds*. Como a base apresenta desbalanceamento moderado entre dias chuvosos e não chuvosos, deu-se atenção especial ao *recall* da classe minoritária (chuva), por ser a métrica mais relevante do ponto de vista prático: deixar de prever um dia chuvoso (falso negativo) tende a ser mais custoso do que prever chuva e ela não ocorrer.

Este artigo está organizado da seguinte forma. A Seção II apresenta uma revisão de trabalhos relacionados. A Seção III descreve o conjunto de dados, as etapas de pré-processamento, a seleção de atributos e os modelos investigados. A Seção IV apresenta os experimentos e resultados obtidos. A Seção V apresenta as conclusões e direções futuras. Por fim, a Seção VI lista as referências.

2 Trabalhos Relacionados

A previsão de chuva por meio de técnicas de Aprendizado de Máquina tem recebido atenção crescente na literatura, em razão da disponibilidade cada vez maior de dados meteorológicos históricos e do bom desempenho relatado por modelos de *ensemble* e redes neurais. Esta seção descreve seis trabalhos recentes que tratam do mesmo problema – classificação binária da ocorrência de chuva a partir de variáveis meteorológicas de superfície.

Wang et al. [1] utilizaram Árvore de Decisão e *Random Forest* (abordagem CART) para prever a ocorrência de chuva. Os autores mostraram que o *Random Forest* estima de forma robusta a probabilidade de chuva em bases de grande volume, superando a árvore isolada em razão do efeito de agregação (*bagging*).

Um modelo híbrido de otimização (*AD-PO-Guided Whale Optimization Algorithm*) foi proposto e comparado com classificadores tradicionais [2]. Embora o algoritmo proposto tenha alcançado 95,99% de acurácia, *Random Forest* e *XGBoost* também apresentaram desempenho competitivo (87,14% e 83,95%), reforçando sua robustez como *baseline*.

Sumi et al. [3] compararam Regressão Linear Múltipla, *Random Forest* e *XGBoost* para

previsão de quantidade diária de chuva, destacando que o *Random Forest* mantém bom desempenho mesmo com dados incompletos – cenário também presente na base deste trabalho.

Em estudo sobre capitais do norte da Índia (1984–2023), *Random Forest* e *Support Vector Classifier* foram comparados usando temperatura do ponto de orvalho e umidade relativa [4]. O *Random Forest* alcançou cerca de 83% de acurácia, com essas duas variáveis apontadas como as de maior poder preditivo – achado convergente com os resultados deste trabalho.

Prathibha et al. [5] avaliaram seis algoritmos na base *WeatherAUS*, reportando que *Random Forest* e *Extra Trees* obtiveram os melhores resultados (85,5% e 85,6%), desempenho muito próximo ao obtido aqui.

Por fim, um estudo sobre dados de Taiwan (1998–2018) comparou *Random Forest* e *CatBoost* com *undersampling* [6]. O *Random Forest* alcançou 70% de acurácia e AUC de 76%, valores inferiores aos obtidos neste trabalho, possivelmente pelas características climáticas distintas e pela redução de dados de treino causada pelo *undersampling*.

Contribuições deste trabalho

Em comparação aos trabalhos descritos, este artigo contribui ao: (i) comparar quatro famílias distintas de classificadores – *ensemble* de árvores, *boosting*, rede neural e regressão logística polinomial – sob o mesmo protocolo experimental; (ii) tratar o desbalanceamento de classes por ponderação, sem reduzir o volume de treino; (iii) utilizar uma base regional (São Carlos – SP) construída a partir de dados brutos horários do INMET; e (iv) priorizar o *recall* da classe minoritária na escolha do melhor modelo, evidenciando que o modelo de maior acurácia (*Random Forest*) não é necessariamente o mais adequado quando o custo de um falso negativo é elevado.

3 Material e Métodos

3.1 O Conjunto de Dados

A base foi construída a partir dos dados históricos horários do INMET, referentes à estação automática de São Carlos – SP (código A711), no período de setembro de 2006 a 2025. Os arquivos anuais foram unificados e filtrados para a estação de interesse, totalizando inicialmente mais de 100 mil registros horários.

Os dados horários foram agregados em nível diário: a precipitação horária foi somada, e as demais variáveis foram agregadas pela média diária. A partir da precipitação total diária, criou-se a variável-alvo binária *CHOVEU* (1 se precipitação > 0 mm; 0 caso contrário). Após a agregação:

- **Número de observações (dias):** 7.210;
- **Período coberto:** setembro de 2006 a 2025;
- **Atributos originais (pós-agregação):** 19, incluindo data, precipitação total e 17 variáveis climáticas (pressão, temperaturas, umidade, radiação solar e vento).

As variáveis incluem pressão atmosférica (média, máxima e mínima), radiação global, temperatura do ar, temperatura do ponto de orvalho (média, máxima e mínima), temperatura máxima e mínima do ar, umidade relativa (média, máxima e mínima), direção do vento, rajada máxima e velocidade do vento.

3.2 Exploração e Pré-processamento

Remoção de atributos redundantes. Colunas de máximos/mínimos horários redundantes com suas médias diárias foram removidas, reduzindo a base de 19 para 11 colunas (data, precipitação, alvo e 8 variáveis climáticas).

Dados ausentes. 448 dos 7.210 dias (6,21%) apresentavam ao menos um valor ausente, decorrente de falhas pontuais dos sensores. Por se tratar de série temporal, os valores ausentes foram tratados por **interpolação temporal** (`interpolate(method='time')`), com preenchimento posterior/anterior nas extremidades. Após esse procedimento, não restaram valores ausentes.

Normalização. Para os modelos sensíveis à escala (MLP e Regressão Logística Polinomial), aplicou-se `StandardScaler`, ajustado apenas no treino para evitar vazamento de dados. Modelos baseados em árvores (*Random Forest* e *XGBoost*) dispensam essa etapa.

Transformação de variáveis. Não havia variáveis categóricas na base; todos os atributos preditores são numéricos contínuos. A variável-alvo foi codificada diretamente a partir do limiar de precipitação.

Análise exploratória. A Figura 1 resume a distribuição da variável-alvo e a Figura 2 matriz de correlação entre as variáveis. Observa-se desbalanceamento moderado entre dias com e sem chuva, além de forte correlação positiva entre radiação global e temperatura do ar, e correlação positiva do alvo com a umidade relativa e o ponto de orvalho. Dias chuvosos tendem a apresentar maior umidade, menor radiação solar e ponto de orvalho mais elevado.




Figura 1: Distribuição da variável-alvo CHOVEU.

3.3 Seleção de Atributos

Dado o número reduzido de variáveis climáticas (8 atributos preditores), todas fisicamente relevantes para o fenômeno de precipitação, não foi aplicada redução formal de dimensionalidade (PCA) ou seleção automática (RFE). A seleção foi conduzida em duas etapas: (i) remoção manual de variáveis redundantes na fase de pré-processamento (Seção III.B); e (ii) análise *a posteriori* da importância de atributos via `feature_importances_` do *Random Forest* (Figura 3, Seção IV). Essa análise mostrou que umidade relativa, temperatura do ponto de orvalho e radiação global concentram a maior parte da importância preditiva,




Figura 2: Mapa de correlação entre as variáveis.

enquanto as variáveis de vento apresentam contribuição individual mais modesta, porém relevante. Optou-se por manter todos os 8 atributos no treinamento final, uma vez que a remoção das variáveis de menor importância não produziu ganho de desempenho em testes preliminares.

3.4 Modelos de Classificação

O problema foi tratado exclusivamente como classificação binária supervisionada, com quatro modelos comparados.

(1) **Random Forest.** *Ensemble* de 100 árvores (`n_estimators=100`), cada uma treinada sobre amostra *bootstrap* e subconjunto aleatório de atributos por divisão. Utilizou-se `class_weight='balanced'` para compensar o desbalanceamento, sem limitação explícita de profundidade.

(2) **XGBoost.** Classificador de *Gradient Boosting* com 100 estimadores, taxa de aprendizado 0,1 e profundidade máxima 5. O desbalanceamento foi tratado via `scale_pos_weight`, calculado como a razão entre exemplos das classes majoritária e minoritária no treino.

(3) **Multilayer Perceptron (MLP)**. Rede *feedforward* totalmente conectada, com duas camadas ocultas (100 e 50 neurônios), ativação ReLU, otimizador Adam e máximo de 500 iterações. Entradas padronizadas via `StandardScaler`.

(4) **Regressão Logística Polinomial (grau 2)**. Modelo linear generalizado com expansão polinomial de grau 2 (`PolynomialFeatures`), incluindo termos quadráticos e de interação, seguido de `LogisticRegression` com `class_weight='balanced'` e máximo de 1.000 iterações. O grau 2 introduz não linearidade sem incorrer em sobreajuste excessivo.

3.5 Implementação e Protocolo Experimental

Os modelos foram implementados em Python, usando `scikit-learn` (*Random Forest*, MLP, Regressão Logística) e `xgboost`. O conjunto de dados (7.210 observações, 8 atributos) foi dividido em 70% treino / 30% teste (`random_state=42`, para reprodutibilidade). Também foi aplicada **validação cruzada de 5 *folds*** sobre o conjunto completo, reportando-se acurácia média e desvio padrão.

Os modelos foram avaliados por: **Accuracy** (proporção de previsões corretas), **Precision** (proporção de previsões de chuva corretas), **Recall** (proporção de dias chuvosos corretamente identificados), **F1-score** (média harmônica de Precision e Recall) e **AUC-ROC** (capacidade de discriminação entre classes).

Dado o desbalanceamento moderado da variável-alvo, o *recall* da classe minoritária (chuva) foi adotado como critério de desempate entre modelos com acurácia semelhante, por representar a capacidade de minimizar falsos negativos – mais relevante na prática do que a acurácia global.

4 Experimentos

4.1 Experimentos Realizados

A Tabela 1 resume os hiperparâmetros adotados em cada modelo.

Tabela 1: Hiperparâmetros e configuração de atributos por modelo.

Modelo	Hiperparâmetros	Nº atributos
Random Forest	<code>n_estimators=100</code> ; <code>class_weight=balanced</code> ; <code>random_state=42</code>	8
XGBoost	<code>n_estimators=100</code> ; <code>learning_rate=0.1</code> ; <code>max_depth=5</code> ; <code>scale_pos_weight</code> (balanceado)	8
MLP	2 camadas ocultas (100, 50); <code>activation=relu</code> ; <code>solver=adam</code> ; <code>max_iter=500</code> ; entrada padronizada	8
Reg. Log. Polinomial	grau = 2; <code>class_weight=balanced</code> ; <code>max_iter=1000</code> ; entrada padronizada	8 (expandidos)

A importância relativa de cada atributo, segundo *Random Forest* e XGBoost, é apresentada na Figura 3. As três variáveis mais relevantes – umidade relativa, temperatura do ponto de orvalho e radiação global – concentram juntas mais de 60% da importância total, consistente com o conhecimento físico de que a saturação de umidade do ar é o principal precursor da formação de chuva. Ambos os modelos baseados em árvores concordam quanto às variáveis mais relevantes.




Figura 3: Comparação da importância dos atributos entre Random Forest e XGBoost (10 mais importantes).

A Tabela 2 apresenta o desempenho de cada classificador no conjunto de teste (2.163 observações), para a classe "chuva".

Tabela 2: Desempenho dos classificadores no conjunto de teste (classe "chuva").

Modelo	Accuracy	Precision	Recall	F1-score
Random Forest	0,8419	0,80	0,73	0,76
XGBoost	0,8433	0,74	0,84	0,79
MLP (Rede Neural)	0,8405	0,77	0,78	0,77
Reg. Log. Polinomial	0,8433	0,73	0,86	0,79

A Tabela 3 apresenta os resultados da validação cruzada (5 folds) e os valores de AUC-ROC.

Tabela 3: Estabilidade (validação cruzada de 5 folds) e área sob a curva ROC dos modelos.

Modelo	Acc. média (CV-5)	Desvio ($\pm 2\sigma$)	AUC-ROC
Random Forest	0,8481	0,0391	0,919
XGBoost	0,8305	0,0386	0,919
MLP (Rede Neural)	0,8208	0,0426	0,915
Reg. Log. Polinomial	0,8395	0,0380	0,924

A Figura 4 apresenta as curvas ROC dos quatro modelos, evidenciando desempenho muito próximo entre eles na separação das classes.




Figura 4: Curvas ROC e respectivos valores de AUC para os quatro modelos avaliados.

4.2 Resultados

Os resultados das Tabelas 2 e 3 mostram que os quatro modelos atingiram desempenho global muito semelhante em **Accuracy**, todos na faixa de 0,84, indicando que a relação entre as variáveis climáticas selecionadas e a ocorrência de chuva é capturada de forma comparável por *ensembles* de árvores, redes neurais e modelos lineares generalizados com expansão polinomial.

Diferenças relevantes emergem no **trade-off entre Precision e Recall** da classe minoritária. O *Random Forest* apresentou a maior *Precision* (0,80) e a maior estabilidade em validação cruzada (0,8481), porém o menor *Recall* (0,73), indicando maior tendência a falsos negativos. Em contraste, a **Regressão Logística Polinomial** obteve o maior *Recall* (0,86), F1-score empatado com o XGBoost (0,79) e o maior **AUC-ROC** (0,924), evidenciando melhor poder de discriminação e maior sensibilidade para identificar dias chuvosos – métrica mais relevante quando deixar de prever chuva é mais custoso do que o inverso. O **XGBoost** apresentou desempenho intermediário e equilibrado (*Precision* 0,74; *Recall* 0,84; AUC 0,919, idêntica ao *Random Forest*). O **MLP** apresentou o desempenho mais modesto, tanto em acurácia de validação cruzada (0,8208, maior desvio padrão) quanto em AUC (0,915), possivelmente pela limitada quantidade de dados frente à capacidade de representação da rede.

A análise de importância de atributos confirma a coerência física dos modelos: umidade relativa ($\approx 0,30$) e temperatura do ponto de orvalho ($\approx 0,19$) concentram quase metade do poder preditivo do *Random Forest*, seguidas por radiação global ($\approx 0,125$) e pressão atmosférica ($\approx 0,10$). As variáveis de vento contribuem conjuntamente com cerca de 19% da importância total, com boa concordância qualitativa entre *Random Forest* e XGBoost.

Em síntese, embora o *Random Forest* seja o modelo mais estável e com maior acurácia média em validação cruzada, a **Regressão Logística Polinomial de grau 2** se mostrou a mais adequada quando o critério de decisão prioriza o *Recall* e o AUC-ROC, sem incorrer no custo computacional e na menor interpretabilidade de modelos mais complexos.

5 Conclusão

Este trabalho abordou a previsão da ocorrência diária de chuva em São Carlos – SP, como classificação binária supervisionada, a partir de dados horários do INMET (2006–2025), totalizando 7.210 observações e 8 atributos preditores. Foram comparados quatro modelos – *Random Forest*, XGBoost, MLP e Regressão Logística Polinomial de grau 2 – sob o mesmo protocolo experimental (divisão 70/30, validação cruzada de 5 *folds* e ponderação de classes).

Os quatro modelos atingiram acurácia semelhante (em torno de 0,84), indicando que a relação entre as variáveis meteorológicas de superfície e a ocorrência de chuva é bem capturada por diferentes paradigmas de Aprendizado de Máquina. Considerando métricas mais sensíveis ao desbalanceamento – *Recall* e AUC-ROC –, a Regressão Logística Polinomial se destacou como o modelo mais adequado (*Recall* = 0,86; AUC = 0,924), enquanto o *Random Forest* foi o mais estável e preciso. O XGBoost apresentou o melhor equilíbrio entre *Precision* e *Recall*, e o MLP teve o desempenho mais modesto, possivelmente pela quantidade de dados relativamente limitada.

A análise de importância indicou que umidade relativa e temperatura do ponto de orvalho são as variáveis com maior poder preditivo, seguidas por radiação global e pressão atmosférica – resultado consistente com a literatura e com o conhecimento físico do fenômeno.

Como trabalhos futuros, sugere-se: (i) otimização de hiperparâmetros (*Grid Search* ou *Bayesian Optimization*), especialmente para o MLP; (ii) incorporação de variáveis defasadas no tempo (*lag features*) e sazonais explícitas; (iii) extensão do problema para regressão da quantidade de chuva; (iv) comparação com técnicas de balanceamento como SMOTE; e (v) validação do modelo em outras estações meteorológicas do estado de São Paulo.

Referências

Referências

- [1] Wang, D. et al. (2023). *Accuracy Prediction of Rainfall Using Decision Tree Algorithm and Random Forest*. In: Proceedings of ICACTCE'23. LNNS, vol. 735. Springer, Cham. https://doi.org/10.1007/978-3-031-37164-6_25
- [2] Autores diversos (2024). *Rainfall classification and forecasting based on a novel voting adaptive dynamic optimization algorithm*. Frontiers in Environmental Science, 12:1417664. <https://doi.org/10.3389/fenvs.2024.1417664>
- [3] Sumi, S. M. et al. (2021). *Machine learning techniques to predict daily rainfall amount*. Journal of Big Data, 8, 153. <https://doi.org/10.1186/s40537-021-00545-4>
- [4] Autores diversos (2025). *Efficacy of machine learning in simulating precipitation and its extremes over the capital cities in North Indian states*. PMC – National Library of Medicine. <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC11937502/>
- [5] Prathibha, K., Rithvik Reddy, G., Kosre, H., Lohith Kumar, K., Rajak, A., Tripathi, R. (2023). *Rainfall Prediction Using Machine Learning*. In: Machine Intelligence Techniques for Data Analysis and Signal Processing. LNEE, vol. 997. Springer, Singapore. https://doi.org/10.1007/978-981-99-0085-5_37

- [6] Autores diversos (2024). *Predicting Rainfall Using Random Forest and CatBoost: A Case Study on Taiwan Meteorological Data (1998–2018)*. In: Proceedings of ICGRE. https://avestia.com/CSEE2024_Proceedings/files/paper/ICGRE/ICGRE_146.pdf
- [7] Instituto Nacional de Meteorologia (INMET). *Banco de Dados Meteorológicos – Dados Históricos*. <https://portal.inmet.gov.br/dadoshistoricos>. Acesso em: 2026.
- [8] Pedregosa, F. et al. (2011). *Scikit-learn: Machine Learning in Python*. JMLR, 12, 2825–2830.
- [9] Chen, T., Guestrin, C. (2016). *XGBoost: A Scalable Tree Boosting System*. In: Proceedings of KDD '16, 785–794. <https://doi.org/10.1145/2939672.2939785>